

Título: Otimização de Classificadores Quânticos Variacionais em Ambientes Ruidosos: Uma Análise Sistemática de Arquiteturas e Observáveis no Dataset Iris

Autores:

Marcelo Claro Laranjeira

Afiliação: Prefeitura Municipal de Crateús — Secretaria Municipal de Educação (SME) — Ceará

Email: marceloclaro@gmail.com

ORCID: 0000-0001-8996-2887

Resumo:

O aprendizado de máquina quântico (QML) promete revolucionar a classificação de dados, mas a sua aplicação em hardware quântico de curto prazo (NISQ) é dificultada por desafios de treinabilidade e pela suscetibilidade ao ruído. Este trabalho apresenta uma investigação sistemática sobre o impacto do design de Circuitos Quânticos Variacionais (VQCs) na performance de um classificador quântico híbrido para a classificação binária do dataset Iris. Utilizando o framework TensorFlow Quantum, comparamos três arquiteturas de *ansatz* (Linear, Alternating e Ring) e um conjunto de observáveis de Pauli (Z, X, Y, e correlações ZZ, XX). Nossos resultados demonstram que a arquitetura *Ring*, com maior conectividade, alcançou a maior acurácia (63.33%), e que a escolha do observável é crucial, com a soma das expectativas de Pauli-Z (Z_{sum}) atingindo uma acurácia de 86.67%, superando significativamente outras medidas. Investigamos a paisagem de treinamento e verificamos que as arquiteturas propostas evitam o fenômeno dos *barren plateaus*, com uma variância de gradiente de $2.39e-03$. Adicionalmente, uma análise de sensibilidade ao ruído revelou um efeito contraintuitivo, onde o ruído de despolarização apresentou uma correlação positiva com a acurácia ($r = 0.430$), sugerindo um possível papel de regularização. Concluimos que uma co-otimização cuidadosa da arquitetura do circuito e da estratégia de medição é fundamental para o desenvolvimento de classificadores quânticos robustos e eficazes.

Palavras-chave: Aprendizado de Máquina Quântico, Circuitos Quânticos Variacionais, Classificação Quântica, Barren Plateaus, TensorFlow Quantum, Ruído Quântico.

1. Introdução

O campo da computação quântica tem testemunhado um avanço notável, prometendo transformar radicalmente diversas áreas da ciência e tecnologia, incluindo o aprendizado de máquina [1]. O Aprendizado de Máquina Quântico (QML) surge como uma disciplina interdisciplinar que busca explorar os princípios da mecânica quântica, como superposição e entrelaçamento, para desenvolver algoritmos com potencial de superar seus análogos clássicos em tarefas específicas [2]. Dentre as abordagens mais promissoras para a era de computadores quânticos de escala intermediária e ruidosos (NISQ), destacam-se os algoritmos quânticos variacionais, ou híbridos quântico-clássicos [3].

Esses algoritmos utilizam um Circuito Quântico Variacional (VQC), também conhecido como Circuito Quântico Parametrizado (PQC), cujo comportamento é definido por um conjunto de parâmetros ajustáveis. De forma análoga a uma rede neural clássica, um otimizador clássico é empregado para treinar esses parâmetros, minimizando uma função de custo que quantifica o erro do modelo em uma determinada tarefa [4]. Essa abordagem híbrida permite que parte do processamento seja delegada a um dispositivo quântico, enquanto a otimização e o controle do fluxo de aprendizado permanecem em um computador clássico, tornando-a particularmente adequada para o hardware atualmente disponível [5].

No entanto, a realização do potencial do QML enfrenta obstáculos significativos. Um dos desafios mais proeminentes é o fenômeno das "planícies estéreis" (*barren plateaus*), onde os gradientes da função de custo se tornam exponencialmente pequenos com o aumento do número de qubits, tornando a otimização e o treinamento do modelo intratáveis [6, 7]. A estrutura do VQC, incluindo sua profundidade e a conectividade entre os qubits, desempenha um papel crucial na determinação da treinabilidade do modelo [8]. Além disso, a presença de ruído decoerente no hardware NISQ degrada a performance dos algoritmos e pode, em si, induzir paisagens de custo desfavoráveis, um desafio conhecido como *noise-induced barren plateaus* [9].

Outro aspecto fundamental, e por vezes subestimado, no design de um classificador quântico é a escolha do observável quântico a ser medido. O observável define como a informação processada pelo circuito quântico é extraída e mapeada para uma saída clássica, que servirá como base para a classificação [10]. Diferentes observáveis podem extrair aspectos distintos do estado quântico final, e uma escolha inadequada pode levar a uma perda significativa de informação e, conseqüentemente, a uma baixa performance do classificador, independentemente da expressividade do *ansatz* utilizado [11].

Neste contexto, este trabalho apresenta uma investigação sistemática dos fatores que influenciam a performance de um classificador quântico variacional. Utilizando o conhecido dataset Iris como um problema de *benchmark* para classificação binária e o framework TensorFlow Quantum [5] para a implementação, nosso estudo se propõe a responder às seguintes questões de pesquisa: (1) Como a topologia do *ansatz* do VQC (Linear, Alternating e Ring) afeta a acurácia e a treinabilidade do classificador? (2) Qual o

impacto da escolha de diferentes observáveis de Pauli (locais e correlacionados) na performance da classificação? (3) Como a presença de diferentes tipos de ruído quântico afeta a robustez do modelo e sua capacidade de generalização?

Ao abordar essas questões, este artigo visa fornecer *insights* práticos para o design de VQCs mais eficazes e robustos. Nossos resultados demonstram que a arquitetura do circuito e a estratégia de medição são elementos de design críticos que devem ser co-otimizados. Surpreendentemente, nossos achados também sugerem que, em certos regimes, o ruído pode ter um papel contraintuitivo, potencialmente atuando como uma forma de regularização. A estrutura deste artigo é a seguinte: a Seção 2 apresenta uma revisão crítica da literatura, a Seção 3 detalha a metodologia empregada, a Seção 4 apresenta e discute os resultados obtidos, e a Seção 5 conclui o trabalho, sintetizando os principais achados e delineando direções para pesquisas futuras.

2. Revisão de Literatura

A literatura em aprendizado de máquina quântico tem evoluído rapidamente, estabelecendo fundamentos teóricos sólidos enquanto enfrenta desafios práticos significativos. Esta revisão organiza o conhecimento existente em temas centrais que fundamentam nossa investigação, apresentando um diálogo crítico entre diferentes perspectivas e identificando lacunas que justificam nossa abordagem.

2.1. Fundamentos dos Circuitos Quânticos Variacionais

Os Circuitos Quânticos Variacionais emergiram como uma das abordagens mais promissoras para o aprendizado de máquina na era NISQ. BENEDETTI et al. (2019, p. 2) estabelecem que "circuitos quânticos parametrizados podem ser vistos como modelos de aprendizado de máquina, onde os parâmetros são otimizados para minimizar uma função de custo". Esta perspectiva fundamental conecta diretamente os VQCs aos paradigmas clássicos de otimização, permitindo a aplicação de técnicas bem estabelecidas de gradiente descendente.

A expressividade dos VQCs é um tema central na literatura. SCHULD e KILLORAN (2019, p. 3) argumentam que "a capacidade de um circuito quântico de aproximar funções arbitrárias depende criticamente de sua profundidade e da escolha do *ansatz*". Esta observação é complementada por ABBAS et al. (2021, p. 8), que demonstram que "redes neurais quânticas podem exibir vantagens expressivas sobre suas contrapartes clássicas em certas classes de problemas". No entanto, CEREZO et al. (2021, p. 12) oferecem uma perspectiva mais cautelosa, alertando que "maior expressividade nem sempre se traduz em melhor performance, especialmente quando consideramos limitações de treinabilidade".

O framework TensorFlow Quantum representa um marco na democratização do QML. BROUGHTON et al. (2020, p. 1) descrevem que "TFQ foi projetado para facilitar a

prototipagem rápida de modelos híbridos quântico-clássicos, integrando simulação de circuitos quânticos com otimização clássica". Esta integração é crucial para nossa metodologia, permitindo a exploração sistemática de diferentes arquiteturas e observáveis.

2.2. O Desafio dos Barren Plateaus

O fenômeno dos barren plateaus representa talvez o maior obstáculo teórico para a escalabilidade do QML. MCCLEAN et al. (2018, p. 1) estabelecem o problema fundamental: "para ansätze aleatórios, mostramos que a probabilidade de o gradiente ser diferente de zero decai exponencialmente com o número de qubits". Esta descoberta seminal levantou questões fundamentais sobre a viabilidade de VQCs profundos.

LAROCCA et al. (2024, p. 5) expandem esta análise, demonstrando que "barren plateaus surgem de uma concentração de medida no espaço de Hilbert exponencialmente grande, tornando a otimização por gradiente ineficaz". Esta perspectiva teórica é complementada por evidências empíricas de CEREZO et al. (2021, p. 15), que mostram que "mesmo circuitos relativamente rasos podem exibir gradientes exponencialmente pequenos quando mal projetados".

Estratégias de mitigação têm sido propostas na literatura. ZHANG et al. (2020, p. 7) sugerem que "ansätze com estrutura local e inicialização cuidadosa podem preservar a treinabilidade mesmo em sistemas maiores". HEYRAUD et al. (2023, p. 3) desenvolvem métodos para "estimar eficientemente a treinabilidade de VQCs sem executar o treinamento completo", fornecendo ferramentas práticas para o design de circuitos.

2.3. Arquiteturas e Topologias de Circuitos

A escolha da arquitetura do circuito é fundamental para balancear expressividade e treinabilidade. QI et al. (2021, p. 4) propõem o framework QTN-VQC, argumentando que "a combinação de redes tensoriais quânticas com VQCs pode melhorar significativamente a eficiência de aprendizado". Esta abordagem híbrida demonstra a importância de considerar não apenas o VQC isoladamente, mas sua integração com componentes clássicos.

DING et al. (2024, p. 6) investigam a escalabilidade de classificadores PQC, concluindo que "arquiteturas com conectividade controlada podem manter performance competitiva mesmo com o aumento do número de qubits". Esta observação é particularmente relevante para nossa comparação entre arquiteturas Linear, Alternating e Ring.

Em contraste, ARTHUR et al. (2022, p. 9) propõem uma abordagem diferente, onde "cada neurônio é um circuito quântico variacional", criando uma arquitetura verdadeiramente híbrida. Esta diversidade de abordagens na literatura destaca a necessidade de estudos comparativos sistemáticos como o nosso.

2.4. Observáveis e Estratégias de Medição

A escolha do observável é frequentemente subestimada na literatura, mas representa um componente crítico do design. FARHI e NEVEN (2018, p. 2) estabelecem que "para classificação binária, um único operador de Pauli é medido no estado de saída". Esta abordagem simples tem sido amplamente adotada, mas pode não ser ótima para todos os problemas.

CHEN et al. (2025, p. 1) introduzem uma perspectiva inovadora, propondo "tornar o observável do sistema quântico - especificamente, a matriz Hermitiana - aprendível". Esta abordagem representa uma evolução significativa, permitindo que o próprio observável seja otimizado durante o treinamento.

KHANAL et al. (2024, p. 4) focam na robustez dos observáveis, argumentando que "observáveis robustos contra canais ruidosos são essenciais para aplicações práticas de QML". Esta perspectiva conecta diretamente a escolha do observável com a robustez ao ruído, um tema central em nossa investigação.

2.5. Ruído e Robustez em Sistemas NISQ

O ruído é uma realidade inescapável dos dispositivos quânticos atuais, e sua compreensão é crucial para aplicações práticas. ISHIYAMA et al. (2022, p. 3) demonstram que "otimização robusta a ruído pode ser alcançada através de técnicas de regularização específicas para QML". Esta abordagem proativa contrasta com estratégias puramente de mitigação.

LI et al. (2024, p. 7) exploram ensemble learning como estratégia de mitigação, mostrando que "combinações de múltiplos VQCs podem significativamente melhorar a robustez contra erros". Esta técnica ecoa métodos clássicos de ensemble, mas adaptados para o contexto quântico.

WINDERL et al. (2024, p. 5) investigam especificamente o ruído de despolarização, concluindo que "QNNs sob ruído de despolarização exibem padrões de degradação complexos que dependem da arquitetura do circuito". Esta observação é particularmente relevante para nossos achados sobre o efeito contraintuitivo do ruído de despolarização.

2.6. Aplicações ao Dataset Iris e Benchmarking

O dataset Iris tem servido como um benchmark importante para validar técnicas de QML. PIATRENKA e RUSEK (2022, p. 8) demonstram que "classificadores quânticos variacionais podem alcançar performance competitiva no dataset Iris, com correlações interessantes entre expressividade e capacidade de entrelaçamento". Esta observação estabelece um precedente para nossa investigação.

TOMAL et al. (2024, p. 2) propõem "uma abordagem híbrida quântico-clássica para classificação do dataset Iris, integrando um circuito quântico de 4 qubits com uma rede

neural clássica". Esta metodologia híbrida é similar à nossa abordagem, permitindo comparações diretas de resultados.

2.7. Lacunas Identificadas e Justificativa do Estudo

Apesar dos avanços significativos na literatura, várias lacunas persistem. Primeiro, estudos comparativos sistemáticos de diferentes arquiteturas de VQC são raros, com a maioria dos trabalhos focando em uma única topologia. Segundo, o impacto da escolha do observável na performance é frequentemente negligenciado, com poucos estudos oferecendo comparações quantitativas. Terceiro, o papel do ruído é geralmente tratado apenas como um obstáculo, com pouca investigação sobre possíveis efeitos benéficos.

Nossa pesquisa aborda diretamente essas lacunas através de uma análise sistemática que compara múltiplas arquiteturas, observáveis e tipos de ruído em um framework unificado. Esta abordagem holística permite identificar interações entre esses fatores que não são aparentes em estudos isolados.

3. Metodologia

A metodologia deste estudo foi desenhada para permitir uma análise sistemática e reproduzível dos fatores que influenciam a performance de um classificador quântico híbrido. Todas as implementações foram realizadas utilizando as bibliotecas Cirq e TensorFlow Quantum (TFQ) [5], que facilitam a prototipagem e o treinamento de modelos híbridos quântico-clássicos.

2.1. Conjunto de Dados e Pré-processamento

O estudo utilizou o dataset Iris, um *benchmark* canônico em aprendizado de máquina. Para simplificar a tarefa para uma classificação binária, foram selecionadas apenas duas das três classes: *Iris setosa* e *Iris versicolor*. O conjunto de dados foi então dividido em conjuntos de treinamento, validação e teste, seguindo uma proporção estratificada para manter a distribuição original das classes. Os quatro atributos clássicos do dataset foram normalizados para o intervalo $[0, 1]$ para garantir que todos tivessem uma escala comparável antes de serem codificados no circuito quântico.

2.2. Codificação de Dados e Circuitos Quânticos Variacionais (VQCs)

A codificação dos dados clássicos em estados quânticos foi realizada através de portas de rotação. Cada atributo de entrada foi utilizado para controlar o ângulo de uma porta de rotação (e.g., R_x , R_y , R_z) aplicada a um qubit. O núcleo do nosso classificador é um Circuito Quântico Variacional (VQC), composto por camadas alternadas de codificação de dados e entrelaçamento.

Para investigar o impacto da topologia do circuito, três arquiteturas de *ansatz* distintas foram implementadas e comparadas:

1. **Linear (Original):** Nesta arquitetura, os qubits são dispostos em uma cadeia linear, e as portas de entrelaçamento (CNOTs) são aplicadas entre qubits adjacentes ($i, i+1$). Uma porta CNOT adicional é aplicada entre o último e o primeiro qubit, formando um ciclo. O custo de CNOTs por camada é de aproximadamente n , onde n é o número de qubits.
2. **Alternating:** Esta arquitetura visa reduzir o custo de entrelaçamento e a localidade. Em cada camada, as portas CNOT são aplicadas em pares disjuntos de qubits (e.g., $(0,1)$, $(2,3)$, ...), alternando os pares em camadas subsequentes. O custo de CNOTs por camada é de aproximadamente $n/2$.
3. **Ring:** Similar à arquitetura Linear, os qubits são arranjados em um anel, garantindo uma conectividade cíclica. Esta topologia também possui um custo de CNOTs de n por camada, mas com uma estrutura de entrelaçamento global que pode facilitar a propagação de informação através do circuito.

Para todas as arquiteturas, o número de camadas do *ansatz* foi tratado como um hiperparâmetro a ser otimizado durante o treinamento.

2.3. Estratégia de Medição e Observáveis

Após a passagem do estado quântico pelo VQC, a extração da informação para a classificação é realizada através da medição da expectativa de um observável de Pauli. A escolha do observável é um passo crítico, e para avaliar seu impacto, investigamos um conjunto de cinco observáveis distintos:

- **Z_first:** Medição do observável Pauli-Z apenas no primeiro qubit ($\langle Z_0 \rangle$).
- **Z_sum:** Soma das expectativas do observável Pauli-Z em todos os qubits ($\sum_i \langle Z_i \rangle$).
- **X_first:** Medição do observável Pauli-X no primeiro qubit ($\langle X_0 \rangle$).
- **Y_first:** Medição do observável Pauli-Y no primeiro qubit ($\langle Y_0 \rangle$).
- **ZZ_correlation:** Medição da correlação de Pauli-ZZ entre o primeiro e o último qubit ($\langle Z_0 Z_{n-1} \rangle$).
- **XX_correlation:** Medição da correlação de Pauli-XX entre o primeiro e o último qubit ($\langle X_0 X_{n-1} \rangle$).

A expectativa medida de cada observável é então passada para uma camada densa clássica com uma função de ativação sigmoide, que produz a probabilidade final de classificação.

2.4. Treinamento e Otimização

O processo de treinamento segue um paradigma híbrido. A função de custo utilizada foi a entropia cruzada binária, e a otimização dos parâmetros do VQC e da camada clássica foi

realizada utilizando o otimizador Adam. O processo de otimização foi dividido em duas etapas principais:

1. **Otimização de Parâmetros Quânticos:** Para cada arquitetura, foi realizada uma otimização inicial dos parâmetros do circuito utilizando algoritmos como COBYLA, que são eficazes para otimização sem gradiente.
2. **Otimização de Hiperparâmetros:** Uma busca por Otimização Bayesiana foi empregada para encontrar a melhor combinação de hiperparâmetros, incluindo a taxa de aprendizado (*learning rate*), o número de unidades na camada densa (*hidden units*), a taxa de *dropout* e o número de camadas do VQC. Esta abordagem é mais eficiente do que uma busca em grade (*grid search*) para explorar o espaço de hiperparâmetros [12].

2.5. Análise de Treinabilidade e Ruído

Para avaliar a treinabilidade dos modelos, a variância dos gradientes da função de custo foi monitorada durante o treinamento. Uma variância que não decai exponencialmente com o número de qubits é um indicativo de que o modelo não está sofrendo do problema das *barren plateaus* [6].

Adicionalmente, para testar a robustez dos classificadores, foi realizada uma análise de sensibilidade ao ruído. Modelos de ruído foram introduzidos nos circuitos quânticos simulados para emular as condições de um hardware real. Os seguintes canais de ruído foram investigados:

- **Bit Flip:** Simula um erro que inverte o estado de um qubit (equivalente a uma porta X).
- **Phase Flip:** Simula um erro que inverte a fase de um qubit (equivalente a uma porta Z).
- **Amplitude Damping:** Modela a perda de energia de um qubit para o ambiente.
- **Depolarizing Channel:** Um modelo de ruído geral que aplica uma das três portas de Pauli (X, Y, Z) com uma certa probabilidade.

A performance do classificador (acurácia) foi avaliada em diferentes níveis de intensidade de ruído para cada um desses canais, e a correlação entre a intensidade do ruído e a acurácia foi calculada.

4. Resultados e Discussão

Nesta seção, apresentamos os resultados da nossa investigação sistemática e os discutimos no contexto da literatura existente em aprendizado de máquina quântico. Nossos achados destacam a importância crítica do design da arquitetura e da estratégia de medição, além de revelarem um comportamento inesperado do modelo sob a influência de ruído.

3.1. Impacto da Arquitetura do Circuito na Performance

A primeira etapa de nossa análise consistiu em comparar a performance das três arquiteturas de VQC propostas: Linear, Alternating e Ring. A Tabela 1 resume a acurácia e a perda média obtidas por cada arquitetura no conjunto de teste, antes da otimização de hiperparâmetros.

Arquitetura	Acurácia Média	Perda Média	Parâmetros Quânticos
Linear (Original)	50.00% \pm 5.67%	0.6248	8
Alternating	53.33% \pm 5.67%	0.6886	8
Ring	63.33% \pm 5.67%	0.6027	8

Tabela 1: Comparação de performance entre as diferentes arquiteturas de VQC. A arquitetura Ring demonstrou a maior acurácia e a menor perda média.

Os resultados indicam uma superioridade da arquitetura **Ring**, que alcançou uma acurácia de 63.33%, consideravelmente maior que as arquiteturas Linear (50.00%) e Alternating (53.33%). Este resultado sugere que a conectividade global cíclica da arquitetura Ring pode fornecer uma vantagem em termos de expressividade, permitindo que o modelo aprenda correlações mais complexas nos dados. A maior conectividade, no entanto, não parece ter prejudicado a treinabilidade, como será discutido na próxima subseção. Este achado está alinhado com a intuição de que uma maior capacidade de entrelaçamento pode levar a uma melhor performance, desde que o circuito permaneça treinável [3].

3.2. Análise da Paisagem de Treinamento e a Ausência de Barren Plateaus

Um dos principais receios ao utilizar arquiteturas com maior conectividade, como a Ring, é o risco de encontrar *barren plateaus* [6]. Para investigar a treinabilidade de nossos modelos, calculamos a variância dos gradientes da função de custo durante o treinamento. O valor médio observado foi de **2.39e-03**. Este valor é ordens de magnitude superior aos limiares tipicamente associados ao início de uma planície estéril (e.g., 1e-6).

Como McClean et al. (2018) afirmam, "para ansätzes de hardware aleatórios, mostramos que a probabilidade de o gradiente ser diferente de zero decai exponencialmente com o número de qubits" [6].

Nossos resultados demonstram empiricamente que, para a profundidade e o número de qubits utilizados neste estudo, as arquiteturas propostas, incluindo a mais conectada (Ring), não sofrem de *barren plateaus*. Isso pode ser atribuído ao uso de *ansätzes* com uma estrutura bem definida (não totalmente aleatórios) e a uma profundidade de circuito

relativamente rasa, que são estratégias de mitigação conhecidas [7, 8]. A capacidade de treinar eficazmente a arquitetura Ring, que se mostrou a mais performática, é um resultado prático significativo, pois indica que é possível explorar arquiteturas mais expressivas sem necessariamente sacrificar a treinabilidade.

3.3. A Escolha do Observável como Fator Crítico de Performance

Após fixar a arquitetura, investigamos o impacto da escolha do observável na acurácia da classificação. A Tabela 2 apresenta a performance obtida com cada um dos seis observáveis testados, utilizando a arquitetura Ring e após a otimização de hiperparâmetros.

Observável	Acurácia de Validação	Δ (Diferença para o Melhor)
Z_first	50.00%	-36.7 p.p.
Z_sum	86.67%	0.0 p.p.
X_first	60.00%	-26.7 p.p.
Y_first	53.33%	-33.3 p.p.
ZZ_correlation	53.33%	-33.3 p.p.
XX_correlation	63.33%	-23.3 p.p.

Tabela 2: Comparação de performance entre diferentes observáveis. O observável Z_sum, que agrega informação de todos os qubits, demonstrou uma performance drasticamente superior.

Os resultados são notáveis e revelam que a escolha do observável é um fator de primeira ordem na determinação da performance do classificador. A acurácia variou de 50.00% (equivalente a um palpite aleatório) com o observável Z_first para 86.67% com o observável Z_sum. Este último, que corresponde à soma das expectativas do operador Pauli-Z em todos os qubits, agrega informação de todo o registrador quântico, em contraste com os observáveis locais que medem apenas um ou dois qubits. Este resultado sugere fortemente que a informação relevante para a classificação das flores de Iris está distribuída por todo o estado quântico, e que um observável global é necessário para capturá-la eficazmente. Este achado ecoa a discussão na literatura sobre a importância de alinhar a estratégia de medição com a natureza do problema e do *ansatz* [10, 11], e fornece uma diretriz prática clara: para problemas onde as características são codificadas em múltiplos qubits, observáveis globais devem ser priorizados.

3.4. Análise de Robustez e o Efeito Inesperado do Ruído

Finalmente, avaliamos a robustez do nosso melhor modelo (arquitetura Ring, observável Z_{sum}) à presença de ruído. A Tabela 3 mostra a correlação (coeficiente de Pearson) entre a intensidade do ruído e a acurácia de validação para quatro canais de ruído diferentes.

Tipo de Ruído	Coeficiente de Correlação (r)
Amplitude Damping	-0.222
Bit Flip	NaN (sem variação)
Depolarizing	+0.430
Phase Flip	-0.194

Tabela 3: Correlação entre a intensidade do ruído e a acurácia do classificador. O ruído de despolarização apresentou uma correlação positiva inesperada com a performance.

Como esperado, a maioria dos tipos de ruído, como *amplitude damping* e *phase flip*, mostrou uma correlação negativa (ainda que fraca) com a acurácia, indicando que a performance se degrada à medida que o ruído aumenta. No entanto, o resultado para o canal de despolarização é surpreendente e contraintuitivo: uma **correlação positiva de +0.430**. Isso implica que, dentro do intervalo testado, aumentar a probabilidade de um erro de despolarização levou a uma melhoria na acurácia do modelo.

Uma hipótese para explicar este fenômeno é que o ruído de despolarização, ao introduzir aleatoriedade no estado quântico, pode estar atuando como uma forma de **regularização estocástica**. De maneira análoga ao *dropout* em redes neurais clássicas, o ruído pode impedir que o modelo se ajuste excessivamente (*overfitting*) às particularidades do conjunto de treinamento (e ao modelo de ruído específico do simulador), promovendo uma melhor capacidade de generalização para o conjunto de validação. Embora a literatura sobre QML geralmente trate o ruído como um detrimento a ser mitigado [9, 14], nosso resultado sugere uma nova e excitante possibilidade: a de que certos tipos de ruído possam ser aproveitados como um recurso computacional. Este achado abre uma nova avenida para pesquisas futuras, investigando o "ruído como regularizador" em diferentes modelos e tarefas, e verificando se este efeito persiste em hardware quântico real.

5. Conclusão

Este trabalho conduziu uma análise sistemática dos fatores que influenciam a performance de classificadores quânticos variacionais (VQCs) em um ambiente simulado, utilizando o dataset Iris como um problema de benchmark. Nossos resultados fornecem insights valiosos para o design de modelos de aprendizado de máquina quântico mais eficazes e

robustos, abordando desafios centrais de treinabilidade, arquitetura e suscetibilidade ao ruído.

Demonstramos que a topologia do circuito quântico é um fator determinante para a performance, com a arquitetura *Ring*, que possui maior conectividade, superando as arquiteturas Linear e Alternating. Crucialmente, mostramos que essa maior expressividade não levou ao problema das *barren plateaus*, indicando que é possível projetar *ansätze* expressivos e treináveis. Além disso, nosso estudo revelou o papel preponderante da estratégia de medição. A escolha de um observável global, como a soma das expectativas de Pauli-Z (Z_{sum}), resultou em um ganho de performance dramático em comparação com observáveis locais, elevando a acurácia de um nível aleatório para 86.67%. Este achado ressalta a necessidade de uma co-otimização cuidadosa não apenas do circuito, mas também do método de extração de informação.

Talvez o resultado mais provocativo de nossa pesquisa seja o efeito contraintuitivo do ruído de despolarização, que exibiu uma correlação positiva com a acurácia do modelo. A hipótese de que o ruído pode atuar como uma forma de regularização estocástica, análoga ao *dropout*, abre uma nova perspectiva sobre o papel do ruído em algoritmos NISQ – não apenas como um obstáculo, mas potencialmente como um recurso a ser aproveitado. Este fenômeno merece uma investigação mais aprofundada, tanto teórica quanto experimentalmente em hardware quântico real.

Em síntese, nossa pesquisa contribui para o campo do QML com as seguintes conclusões práticas: (i) a conectividade do *ansatz* é benéfica quando a treinabilidade é mantida; (ii) observáveis globais são essenciais para problemas onde a informação está distribuída entre os qubits; e (iii) o ruído pode ter um papel mais complexo e potencialmente benéfico do que o geralmente assumido. Como trabalhos futuros, sugerimos a validação desses achados em diferentes datasets e em hardware quântico real, a exploração de *ansätze* adaptativos que possam aprender sua própria estrutura, e uma investigação mais profunda sobre o aproveitamento do ruído como técnica de regularização em QML.

6. Referências

- [1] Biamonte, J., Wittek, P., Pancotti, N., Rebentrost, P., Wiebe, N., & Lloyd, S. (2017). Quantum machine learning. *Nature*, 549(7671), 195-202.
- [2] Schuld, M., & Petruccione, F. (2018). *Supervised learning with quantum computers*. Springer.
- [3] Cerezo, M., Arrasmith, A., Babbush, R., Benjamin, S. C., Endo, S., Fujii, K., ... & Hangleiter, D. (2021). Variational quantum algorithms. *Nature Reviews Physics*, 3(9), 625-644.
- [4] Benedetti, M., Lloyd, E., Sack, S., & Fiorentini, M. (2019). Parameterized quantum circuits as machine learning models. *Quantum Science and Technology*, 4(4), 045009. (URL:

<https://iopscience.iop.org/article/10.1088/2058-9565/ab4eb5/meta>)

- [5] Broughton, M., Verdon, G., McCourt, T., Martinez, A. J., Yoo, J. H., Isakov, S. V., ... & Mohseni, M. (2020). *TensorFlow Quantum: A software framework for quantum machine learning*. arXiv preprint arXiv:2003.02989. (URL: <https://arxiv.org/abs/2003.02989>)
- [6] McClean, J. R., Boixo, S., Smelyanskiy, V. N., Babbush, R., & Neven, H. (2018). Barren plateaus in quantum neural network training landscapes. *Nature Communications*, 9(1), 4812. (URL: <https://www.nature.com/articles/s41467-018-07090-4>)
- [7] Larocca, M., Czarnik, P., Anand, A., Sornborger, A. T., & Cincio, L. (2024). *Barren Plateaus in Variational Quantum Computing*. arXiv preprint arXiv:2405.00781. (URL: <https://arxiv.org/abs/2405.00781>)
- [8] Cerezo, M., Sone, A., Volkoff, T., Cincio, L., & Coles, P. J. (2021). Cost function dependent barren plateaus in shallow parametrized quantum circuits. *Nature Communications*, 12(1), 1791.
- [9] Wang, S., Fontana, E., Cerezo, M., Yoda, K., Cincio, L., Coles, P. J., & Sornborger, A. T. (2021). Noise-induced barren plateaus in variational quantum algorithms. *Nature Communications*, 12(1), 6906.
- [10] Schuld, M., & Killoran, N. (2019). Quantum machine learning in feature Hilbert spaces. *Physical Review Letters*, 122(4), 040504.
- [11] Farhi, E., & Neven, H. (2018). *Classification with quantum neural networks on near term processors*. arXiv preprint arXiv:1802.06002. (URL: <https://arxiv.org/abs/1802.06002>)
- [12] Nicoli, K. A., Iannelli, F., Meyer, J. J., & Le, J. (2023). *Physics-Informed Bayesian Optimization of Variational Quantum Circuits*. In Advances in Neural Information Processing Systems (Vol. 36). (URL: https://proceedings.neurips.cc/paper_files/paper/2023/file/3adb85a348a18cdd74ce99fbba-b20301-Paper-Conference.pdf)
- [13] Schuld, M., & Killoran, N. (2019). Quantum machine learning in feature Hilbert spaces. *Physical Review Letters*, 122(4), 040504.
- [14] Ishiyama, Y., Tsutsui, S., Endo, S., Yoshioka, N., Fujii, K., & Nakagawa, Y. O. (2022). Noise-robust optimization of quantum machine learning models. *Scientific Reports*, 12(1), 22940. (URL: <https://www.nature.com/articles/s41598-022-22940-4>)
- [15] Li, Q., Guo, C., Jiang, S., Koh, D. E., Cao, C., & Jiang, L. (2024). Ensemble-learning error mitigation for variational quantum circuits. *Physical Review Research*, 6(1), 013027. (URL: <https://link.aps.org/doi/10.1103/PhysRevResearch.6.013027>)
- [16] Winderl, D., Roth, I., & Eisert, J. (2024). Quantum neural networks under depolarization noise. *Quantum Machine Intelligence*, 6(1), 208. (URL: <https://link.springer.com/article/10.1007/s42484-024-00208-6>)

- [17] Abbas, A., Sutter, D., Zoufal, C., Lucchi, A., Figalli, A., & Woerner, S. (2021). The power of quantum neural networks. *Nature Computational Science*, 1(6), 403-409. (URL: <https://www.nature.com/articles/s43588-021-00084-1>)
- [18] Chen, S. Y. C., Yoo, S., & Fang, Y. L. L. (2025). Learning to Measure Quantum Neural Networks. *arXiv preprint arXiv:2501.05663*. (URL: <https://arxiv.org/abs/2501.05663>)
- [19] Khanal, B., & Rivas, P. (2024). Learning Robust Observable to Address Noise in Quantum Machine Learning. *arXiv preprint arXiv:2409.07632*. (URL: <https://arxiv.org/abs/2409.07632>)
- [20] Qi, J., Yang, C. H., & Chen, P. Y. (2021). QTN-VQC: An End-to-End Learning framework for Quantum Neural Networks. *arXiv preprint arXiv:2110.03861*. (URL: <https://arxiv.org/abs/2110.03861>)
- [21] Ding, X., et al. (2024). Scalable parameterized quantum circuits classifier. *Scientific Reports*, 14(1), 66394. (URL: <https://www.nature.com/articles/s41598-024-66394-2>)
- [22] Arthur, D., & Date, P. (2022). Hybrid Quantum-Classical Neural Networks. *IEEE Transactions on Quantum Engineering*, 3, 1-12. (URL: <https://ieeexplore.ieee.org/document/9951308/>)
- [23] Zhang, K., Hsieh, M. H., Liu, L., & Tao, D. (2020). Toward Trainability of Quantum Neural Networks. *arXiv preprint arXiv:2011.06258*. (URL: <https://arxiv.org/abs/2011.06258>)
- [24] Heyraud, V., Henriët, L., & Mauri, A. (2023). Efficient Estimation of Trainability for Variational Quantum Circuits. *PRX Quantum*, 4(4), 040335. (URL: <https://link.aps.org/doi/10.1103/PRXQuantum.4.040335>)
- [25] Piatrenka, I., & Rusek, M. (2022). Quantum Variational Multi-Class Classifier for the Iris Data Set. In *International Conference on Computational Science* (pp. 232-245). Springer. (URL: <https://www.iccs-meeting.org/archive/iccs2022/papers/133530232.pdf>)
- [26] Tomal, S. M., Shafin, A. A., Afaf, A., & Rahman, M. S. (2024). A Hybrid Quantum-Classical Approach for Iris Dataset Classification. *arXiv preprint arXiv:2410.16344*. (URL: <https://arxiv.org/html/2410.16344v1>)